

MLP para mantenimiento predictivo

Grupo 5



Clasificación Binaria en IA

El problema central en este proyecto es aplicar un MLP para **clasificar datos** en dos clases: normal y falla. Este enfoque permite identificar de manera precisa el estado operativo de las máquinas.



Revisión del dataset

El dataset contiene **9.854 filas** y **7 características** para entrenamiento, y **4.224 filas** y **7 características** para prueba, con una distribución equilibrada entre clases normal y failure.




Integración con el Pipeline de Ciencia de Datos

La red neuronal MLP utiliza datos preparados por el pipeline de Ciencia de Datos, evitando inconsistencias y permitiendo comparaciones efectivas con modelos tradicionales sobre el mismo conjunto de datos exportados.




Separación de Datos para Entrenamiento

La separación del dataset en bloques de **entrenamiento**, validación y prueba permite elegir hiperparámetros de manera honesta y evita sesgos.



Arquitectura base del MLP



Componentes de la capa oculta

Cada capa oculta del MLP incluye elementos **esenciales** como Linear, BatchNorm, ReLU y Dropout y Salidas Sigmoid, que permiten aprender representaciones complejas mientras estabilizan y optimizan el entrenamiento, mejorando la precisión del modelo.



Batch Normalization y Dropout

Batch Normalization: Estandariza las activaciones de una capa para que tengan una media cercana a 0 y una desviación estándar de 1

Dropout: Apaga aleatoriamente un subconjunto de neuronas durante el entrenamiento



Beneficios de la arquitectura tipo embudo

La arquitectura tipo embudo, con capas que disminuyen progresivamente, permite aprender combinaciones simples y abstractas de los datos, optimizando la capacidad del modelo y reduciendo el riesgo de sobreajuste en conjuntos de datos tabulares.



Entrenamiento del MLP y optimización

Funcion de perdida: **Binary Cross-Entropy**


Optimizadores: **Adam y SGD.**

Patience: 40




Optimización de Hiperparámetros

Se exploraron **72 combinaciones** de hiperparámetros para mejorar el rendimiento del modelo, incluyendo arquitecturas, tasas de aprendizaje y técnicas de regularización, asegurando una comparación exhaustiva y sistemática de decisiones en el proceso de ajuste.




Comparación SGD y ADAM




Configuración Ganadora del MLP


La mejor configuración del MLP incluye **dos capas** [64,32], una tasa de aprendizaje de 0.01 y un **dropout** de 0.3, logrando un rendimiento sobresaliente en las métricas de validación.



Entrenamiento del MLP Completado





Se reentrenó el mejor modelo con la configuración ganadora, utilizando validación interna para **early stopping**. El tiempo total de entrenamiento fue de 36.3 segundos.




En términos del tamaño de los modelos resultantes, el MLP resulta ser excepcionalmente eficiente, requiriendo menos de 20 KB de espacio en memoria.

Resultados del MLP en Test

El MLP obtuvo un rendimiento sólido en el conjunto de prueba, **logrando un F1 de 0.9444** y un AUC de 0.9889. El early stopping selecciona la epoca con mejor validación antes de que aparezca sobreajuste.



Comparación con Modelos Tradicionales



La **comparación revela** que el MLP supera a modelos simples, aunque **no alcanza** el rendimiento de ensembles avanzados como Gradient Boosting y Random Forest, que son excepcionales para datos tabulares.



Conclusiones

- MLP vs Modelos Tradicionales
- Adam vs. SGD