

Conjunto de datos

Para esta actividad se utilizará una versión adaptada de un conjunto de datos etiquetados para la clasificación de intenciones en inglés (Casanueva et al., 2020). Este tipo de tareas suele formar parte de soluciones basadas en chatbots de asistencia y otros sistemas de procesamiento de lenguaje natural. El dataset se encuentra en el archivo **intent.csv** y contiene las siguientes variables:

- text – Mensaje del usuario.
- category – Intención detectada (77 categorías).

Práctica

Utilizando Python, sin recurrir a otros paquetes externos que no sean los vistos en el curso:

- 1) Realizar un análisis exploratorio de datos utilizando distintos tipos de funciones, gráficas y medidas estadísticas. Presentar los resultados más importantes.
- 2) Preprocesar el conjunto de datos para que pueda utilizarse en modelos de aprendizaje automático teniendo en cuenta:
 - Preprocesamiento de texto.
 - Procesamiento de variables de salida.
 - Representaciones vectoriales del lenguaje.
 - Balance del conjunto de datos.
- 3) Entrenar y mostrar los resultados obtenidos con al menos tres modelos vistos en el curso, teniendo en cuenta:
 - División del conjunto de datos para entrenamiento y prueba.
 - Búsqueda de hiperparámetros para mejorar el rendimiento de los modelos.
 - Evaluación del modelo con las métricas convenientes.

Entrega

- 1) Un archivo .ipynb conteniendo la solución a los incisos 1, 2 y 3.
- 2) Un informe que documente y justifique los distintos pasos realizados, herramientas y técnicas utilizadas.

Referencias

Casanueva, I., Temcinas, T., Gerz, D., Henderson, M. y Vulić, I. (2020). Efficient Intent Detection with Dual Sentence Encoders. En *Proceedings of the 2nd Workshop on NLP for ConvAI - ACL 2020*. <https://arxiv.org/abs/2003.04807>